

유전자 발현 데이터에서 2 단계 특성 선택을 통한 TabPFN 기반 암 아형 분류 모델

Two-Stage Feature Selection for TabPFN-Based Cancer Subtype Classification from Gene Expression Data

요약

본 논문은 약 2 만 개 유전자의 고차원 RNA-seq 데이터로부터 12 개 암종의 분자 아형을 분류하는 방법을 제안한다. 사전학습 트랜스포머 분류기 TabPFN 은 우수한 성능을 보이나 입력 특성이 최대 500 개로 제한되어 고차원 유전자 데이터에 직접 적용할 수 없다는 한계가 있다. 본 연구는 로지스틱 회귀의 순열 중요도와 랜덤 포레스트의 지니 중요도를 순차 적용하여 약 2 만 개 유전자에서 핵심 500 개를 선별하는 2 단계 특성 선택 기반 분류 모델 TS-TabPFN 을 제안한다. TCGA 12 개 암종(총 6,537 샘플)에 대한 5 겹 층화 교차검증 결과, TS-TabPFN 은 전체 특성을 사용한 머신러닝 8 종 및 딥러닝 2 종 비교 모델을 5 개 평가 지표 모두에서 능가하였으며, 12 개 중 10 개 암종에서 최고 성능을 달성하였다. 평균 Weighted F1 0.8469 로 단일 최우수 비교 모델 대비 약 0.025 의 일관된 우위를 보였다.

1. 서론

암의 분자 아형을 정확히 분류하는 것은 환자 맞춤형 치료와 예후 예측의 핵심 과제이다[1]. 최근 RNA-seq 유전자 발현 데이터(약 2 만 개 유전자)를 머신러닝에 적용하는 연구가 활발하다. 정형 데이터 분류 분야에서는 합성 데이터로 사전학습된 후 가중치 갱신 없이 훈련 데이터를 컨텍스트로 입력받아 한 번의 순전파로 예측을 수행하는 사전학습 트랜스포머 모델 TabPFN[2]이 주목받고 있다. 그러나 TabPFN v2 는 입력 특성이 최대 500 개로 제한되어 약 2 만 개 유전자에 직접 적용할 수 없다. 본 논문은 분류에 핵심적인 500 개의 유전자만을 선별하는 2 단계 특성 선택 기반 분류 모델 TS-TabPFN(Two-Stage Feature Selection TabPFN)을 제안하고, TCGA 12 개 암종 데이터셋에 대한 실험을 통해 그 효과를 입증한다.

2. 관련 연구

기존 RNA-seq 기반 암 아형 분류 연구는 XGBoost, LightGBM, 랜덤 포레스트, SVM 등을 활용해 왔으나[3], 약 2 만 개 유전자를 모두 입력으로 사용하여 고차원 저표본 환경에서 과적합 위험이 크다. TabPFN 은 소규모 정형 데이터에서 뛰어난 성능을 보이지만 500 개 특성 제한이 있고, 2025 년 11 월 출시된 TabPFN-


2.5 에서 입력 한도가 2,000 개로 확장되었음에도 약 2 만 개 규모에는 미치지 못한다. 또한 변분 자동인코더, BulkFormer 등 사전학습 기반 차원 축소는 오히려 TabPFN 의 성능을 저하시키며[4], TabPFN-Wide[5]는 추가 사전학습이 필요해 일반 연구자가 활용하기 어렵다. 본 연구는 별도의 사전학습 없이 순차적 특성 선택만으로 원본 발현값을 보존한 채 핵심 부분집합을 선별하여 TabPFN 에 입력하는 방법을 제안한다.

3. 데이터셋

본 연구는 TCGA(The Cancer Genome Atlas)에서 확보한 12 개 암종 데이터셋을 사용하였다[7]. 총 6,537 개의 표본으로 구성되며, 표본 수는 데이터셋별로 약 400~1,000 개, 클래스 수는 2~7 개, 특성 수는 약 1.3 만~2 만 개로 분포한다. 모든 발현값은 로그 변환을 통해 정규화하였다. 다수 데이터셋이 심각한 클래스 불균형(최대 24.7:1)을 보이므로, 가중 평균 기반 평가 지표를 채택하였다.

4. 방법

본 연구가 제안하는 TS-TabPFN 은 2 단계 특성 선택 파이프라인과 TabPFN 추론 단계로 구성된다(그림 1).



4.1 Step 1: LR 기반 순열 중요도 평가

첫 번째 단계에서는 약 2 만 개 특성을 6,000 개로 축소한다. L2 페널티 로지스틱 회귀를 학습한 뒤 각 특성을 셔플하여 손실 변화를 측정하는 순열 중요도로 상위 6,000 개를 선별한다. 이 단계는 각 유전자의 독립적 한계 기여도를 평가하여 노이즈 유전자를 제거하고, 이후 비선형 탐색을 위한 여유를 확보한다.

4.2 Step 2: 랜덤 포레스트 기반 지니 중요도 평가

두 번째 단계에서는 6,000 개를 500 개로 최종 축소한다. 랜덤 포레스트의 지니 불순도 감소량을 바탕으로 상위 500 개를 선별한다. 의사결정트리의 분기 구조는 조건부 관계를 자연스럽게 인코딩하므로, 1 단계의 선형 모델이 포착하지 못한 저차원 비선형 상호작용을 효과적으로 반영한다[6].

4.3 Step 3: TabPFN 을 활용한 분류

선별된 500 개 특성을 입력으로 TabPFN v2 에 적합시킨다. TabPFN 은 사전학습 가중치를 갱신하지 않고 훈련 데이터를 컨텍스트로 입력받아 In-Context Learning 방식으로 예측을 수행한다.

4.4 실험 환경 및 평가지표

평가 방식은 시드를 42 로 고정한 5 겹 층화 교차검증을 사용하였으며, 특성 선택과 모델 적합은 모두 각 fold 의 훈련 데이터에서만 수행하여 데이터 누수를 방지하였다. 평가 지표는 Weighted F1, Weighted Precision, Macro Recall, Accuracy, Weighted AUROC 의 5 가지를 사용하였다. Weighted Recall 은 Accuracy 와 수학적으로 동일하므로 Recall 에 한해 macro 평균을 채택하였다. 비교 모델로는 전체 약 2 만 개 특성을 사용한 머신러닝 8 종(로지스틱 회귀, XGBoost, 랜덤 포레스트, CatBoost, LightGBM, AdaBoost, 엑스트라트리, SVM)과 딥러닝 2 종(MLP, TabNet)을 사용하였다.

5.1 모델 비교 결과

표 1 은 12 개 암종에 대한 5-fold 평균 종합 성능을 보여준다. TS-TabPFN 은 5 개 지표 모두에서 1 위를 기록하였다. Weighted F1 0.8469 는 2 위 LightGBM(0.8220) 대비 +0.0249 높았으며, 특히 Macro Recall 에서 0.8115 를 기록하여 LightGBM(0.7575) 대비 +0.0540 의 큰 격차를 보였다. 이는 TS-TabPFN 이 다수 아형뿐 아니라 소수 아형까지 균등하게 분류함을 의미한다. 딥러닝 비교군인 MLP(F1 0.7810)와 TabNet(F1 0.6479)은 약 20,000 개 특성을 직접 학습하는 과정에서 불안정한 양상을 보인 반면, TS-TabPFN 은 500 개 핵심 유전자만으로 사전학습된 트랜스포머의 사전(prior)을 효과적으로 활용하였다. AUROC 에서 TS-TabPFN 의 0.9548 은 2 위 CatBoost(0.9538)와 표준편차(± 0.040) 범위 내로 실질적으로 동등한 수준이다. 즉, 클래스 확률 추정 측면에서는 트리 기반 부스팅 모델과 유사하지만, 실제 분류 경계를 나타내는 F1-Accuracy-Macro Recall 에서는 TS-TabPFN 이 보다 일관된 우위를 보인다.

5.2 암종별 상세 성능 분석

표 2 는 암종별 Weighted F1 결과를 단일 최우수 비교 모델과 비교한 것이다. 12 개 암종 중 GEA(+0.0641), SKCM(+0.0421), COADREAD(+0.0418) 등 10 개 암종에서 TS-TabPFN 이 최고 성능을 달성하였다. TS-TabPFN 이 최고 성능을 달성하지 못한 2 개 암종은 THCA(-0.0085, LightGBM 우위)와 UCEC(-0.0102, CatBoost 우위)에 불과하였으며, 그 차이도 평균 0.01 수준으로 매우 작다. 12 개 암종 전체 평균 Weighted F1 에서 TS-TabPFN(0.8469)은 단일 최우수 비교 모델인 LightGBM(0.8220) 대비 +0.0249 의 일관된 우위를 유지하였다. 이러한 결과는 본 연구의 2 단계 특성 선택이 생물학적으로 의미 있는 유전자를 효과적으로 선별하여, TabPFN 이 사전학습 사전(prior)을 최대한 활용할 수 있도록 함을 시사한다.

5. 결과

표 1. 12 개 TCGA 암종 데이터셋에 대한 모델별 평균 성능 비교. 5 겹 교차검증에 대한 mean $\pm$ std 표기

Model	Weighted F1	Weighted Precision	Macro Recall	Accuracy	AUROC
Proposed					
TS-TabPFN	0.8469 $\pm$ 0.084	0.8523 $\pm$ 0.083	0.8115 $\pm$ 0.101	0.8501 $\pm$ 0.081	0.9548 $\pm$ 0.040
ML Models					
LightGBM	0.8220 $\pm$ 0.094	0.8272 $\pm$ 0.092	0.7575 $\pm$ 0.126	0.8321 $\pm$ 0.086	0.9511 $\pm$ 0.039
CatBoost	0.8105 $\pm$ 0.104	0.8206 $\pm$ 0.101	0.7343 $\pm$ 0.141	0.8245 $\pm$ 0.093	0.9538 $\pm$ 0.040
XGBoost	0.8125 $\pm$ 0.098	0.8174 $\pm$ 0.098	0.7471 $\pm$ 0.126	0.8214 $\pm$ 0.091	0.9470 $\pm$ 0.041
AdaBoost	0.7797 $\pm$ 0.123	0.7923 $\pm$ 0.118	0.7265 $\pm$ 0.152	0.7865 $\pm$ 0.117	0.9009 $\pm$ 0.067
LogisticRegression	0.7632 $\pm$ 0.109	0.7741 $\pm$ 0.104	0.7199 $\pm$ 0.111	0.7651 $\pm$ 0.108	0.9062 $\pm$ 0.066
RandomForest	0.7582 $\pm$ 0.127	0.7708 $\pm$ 0.130	0.6612 $\pm$ 0.159	0.7844 $\pm$ 0.107	0.9387 $\pm$ 0.055
ExtraTrees	0.7416 $\pm$ 0.128	0.7618 $\pm$ 0.128	0.6456 $\pm$ 0.156	0.7722 $\pm$ 0.107	0.9350 $\pm$ 0.055
SVM(RBF)	0.6878 $\pm$ 0.138	0.7050 $\pm$ 0.135	0.5858 $\pm$ 0.156	0.7209 $\pm$ 0.117	0.9017 $\pm$ 0.066
Deep Learning Models					
MLP	0.7810 $\pm$ 0.110	0.7883 $\pm$ 0.111	0.7245 $\pm$ 0.140	0.7868 $\pm$ 0.105	0.9041 $\pm$ 0.066
TabNet	0.6479 $\pm$ 0.173	0.6543 $\pm$ 0.175	0.5551 $\pm$ 0.199	0.6749 $\pm$ 0.152	0.8002 $\pm$ 0.140

표 2. TS-TabPFN 과 최고 ML 과 F1 정확도 성능 비교

Dataset	TS-TabPFN	Best ML	Best Model
BLCA	0.8756	0.8427	LightGBM
BRCA	0.9308	0.9303	XGBoost
COADREAD	0.7790	0.7373	CatBoost
GEA	0.7580	0.6940	LightGBM
HNSC	0.9044	0.8868	AdaBoost
KIRCKICH	0.9963	0.9822	XGBoost
LGGGBM	0.8660	0.8308	LogisticReg
LUAD	0.8775	0.8627	LightGBM
LUSC	0.8738	0.8629	LightGBM
SKCM	0.7134	0.6712	LightGBM
THCA	0.7628	0.7713	LightGBM
UCEC	0.8252	0.8354	CatBoost
Avg	0.8469	0.8256	

6. 결론

본 논문에서는 고차원 RNA-seq 데이터에 TabPFN 을 효과적으로 적용하기 위해 L2 로지스틱 회귀의 순열 중요도와 랜덤 포레스트의 지니 중요도를 순차 적용하는 2 단계 특성 선택 기반 분류 모델 TS-TabPFN 을 제안하였다. 제안 모델은 약 20,000 개 유전자에서 선별한 500 개 핵심 유전자만으로 TCGA 12 개 암종 중 10 개에서 최고 성능을 달성하였으며, 평균 Weighted F1 0.8469 로 단일 최우수 비교 모델인 LightGBM(0.8220) 대비 +0.0249 향상을 보였다. 사전학습된 TabPFN 의 가중치를 갱신하지 않고 데이터 측면의 적응만으로 이러한 성능을 달성하였다는 점에서, 본 방법론은 별도의 추가 사전학습이나 복잡한 하이퍼파라미터 튜닝 없이도 고차원 RNA-seq 데이터에

TabPFN 을 적용할 수 있는 실용적 접근임을 시사한다. 향후 연구로는 SHAP 기반 앵커 유전자 선택과 스택킹 앙상블(Stacking Ensemble) 확장을 통해 분류 성능을 추가적으로 향상시킬 계획이다.

참고 문헌

- [1] K. A. Hoadley et al., "Cell-of-origin patterns dominate the molecular classification of 10,000 tumors from 33 types of cancer," *Cell*, vol. 173, no. 2, pp. 291-304, 2018.
- [2] N. Hollmann et al., "Accurate predictions on small data with a tabular foundation model," *Nature*, vol. 637, pp. 319-326, 2025.
- [3] F. Alharbi and A. Vakanski, "Machine learning methods for cancer classification using gene expression data: A review," *Bioengineering*, vol. 10, no. 2, p. 173, 2023.
- [4] K. Zhou et al., "Limitations of foundation models for tabular data applied to rna-seq transcriptomics," *bioRxiv*, 2025.
- [5] L. Kolberg et al., "TabPFN-Wide: Extending tabular foundation models for extreme feature counts," in *Proceedings of ICML*, 2025.
- [6] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [7] K. Ellrott et al., "Classification of cancer types using machine learning on transcriptomic data," *Cancer Cell*, 2025.